

POLITECHNIKA WROCŁAWSKA

WYDZIAŁ ELEKTRONIKI

KIERUNEK: Informatyka

SPECJALNOŚĆ: Grafika i Systemy Multimedialne

PRACA DYPLOMOWA MAGISTERSKA

Detekcja manipulacji zawartości zdjęć przy
pomocy metod uczenia głębokiego

Image manipulation detection using deep
learning techniques

AUTOR:

Jarosław Ciołek-Żelechowski

PROMOTOR:

dr inż. Paweł Ksieniewicz

OCENA PRACY:

SPIS TREŚCI

1. Wstęp	2
2. Uczenie maszynowe	3
2.1. Big Data	4
2.2. Rodzaje systemów uczenia maszynowego	5
2.2.1. Miary jakości	7
2.3. Zadanie klasyfikacji binarnej	8
2.3.1. Maszyna wektorów nośnych(SVM)	8
2.4. Głębokie sieci neuronowe	8
2.4.1. VGG	8
3. Analiza istniejących metod w obrębie dziedziny	9
4. Założenia metodologiczne	10
4.1. Wybranie zbiorów danych	10
4.2. Opis wykonanych eksperymentów	10
4.3. Autorska metoda wykorzystania sieci konwolucyjnej w detekcji fałszyfikacji zdjęć	10
4.4. Interpretacja uzyskanych wyników	10
5. Implementacja i interpretacja wyników badań	11
5.1. Implementacja środowiska ramowego wykorzystującego istniejące architektury sieci	11
5.2. Implementacja autorskiej metody wykorzystania uczenia głębokiego w zadaniu klasyfikacji	11
6. Podsumowanie	12
Bibliografia	13
Spis rysunków	14
Spis tabel	15

1. WSTEP

2. UCZENIE MASZYNOWE

Alan Turing w swojej pracy z 1950 roku *Computing Machinery and Intelligence*[12] zdefiniował pojęcie *obiekcji lady Lovelace*. Odnosiło się ono do krótkiej notatki[5] jaką lady Ada Lovelace poczyniła w 1843 roku podczas tłumaczenia na język angielski artykułu Luigi Menabrea[7], który to był streszczeniem wykładu Charlesa Babbage’a wygłoszonego w Turynie w 1841 roku. Wykład dotyczył projektu maszyny analitycznej której zadaniem było zautomatyzowanie niektórych obliczeń związanych z analizą matematyczną. Pojęcie to brzmi następująco:

Maszyna analityczna nie ma na celu zapoczątkowania czegokolwiek. Może wykonywać operacje, które możemy kazać jej przeprowadzać... Jej celem jest zwiększanie dostępności tego co umiemy już wykonać[12]

Turing, przywołał to pojęcie, zastanawiając się nad tym, czy komputery mogą się uczyć, tworzyć nowe rzeczy. Jak pisze on dalej w swoim artykule: problem jest natury programistycznej i wymaga on stworzenia zupełnie innego, jak na tamte czasy, środowiska i sposobu pojmowania nauczania jako takiego. Wierzył jednak, że jest to możliwe.

Termin *Uczenie Maszynowe* po raz pierwszy pojawił się w 1959 roku w pracy naukowej autorstwa Arthura Samuela:

Uczenie maszynowe to dziedzina nauki dająca komputerom możliwość uczenia się bez konieczności ich jawnego programowania.[10]

Praca ta dotyczyła maszyny, która przez ok. 8 godzin *uczyła się* gry w warcaby znając jedynie jej zasady, posiadając pewnego rodzaju funkcję celu (zbijanie pionów przeciwnika), oraz macierz losowych liczb, której to zmiany i przekształcenia miały na celu reprezentować inne podejścia (nową wiedzę). Sprawdzianem sukcesu maszyny, było pokonanie jej twórcy.

Bardziej techniczną definicję podał w 1997 roku Tom Mitchel, w rozdziale otwierającym swoją książki pt. *Machine Learning*:

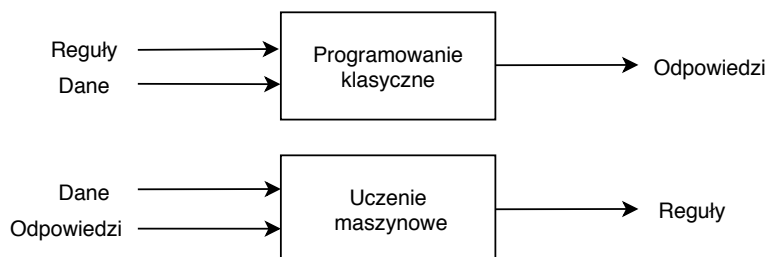
Mówimy, że program komputerowy uczy się na podstawie doświadczenia E w odniesieniu do jakiegoś zadania T i pewnej miary wydajności P , jeśli jego wydajność (mierzona przez P) wobec zadania T wzrasta wraz z nabywaniem doświadczenia E .[8]

Tym samym uczenie maszynowe zostało sprowadzone do problemu, w którym to posiadamy trzy elementy T , P i E . W dalszej części Tom Mitchel podaje przykład powyżej definicji zrealizowanej dla gry w warcaby (wyraźny ukłon w stronę pracy Arthura Samuela[10]):

- Zadanie T : gra w warcaby,
- Miara Wydajności P : procent gier wygranych na oponentów,
- Doświadczenie E : granie partii przeciwko samemu sobie.

Tym samym można rozumieć uczenie maszynowe jako nowy paradygmat programowania. W programowaniu klasycznym, programista definiuje reguły według których program przetwarza dane wejściowe, generując tym samym dane wyjściowe - odpowiedź pracy programu (patrz

rysunek 2.1). W przypadku uczenia maszynowego mamy sytuację w której programista wprowadza dane oraz odpowiedzi i oczekuje uzyskać od programu zestawu reguł, według których dane odpowiedzi zostały przypisane do konkretnych próbek. Reguły te, mają posłużyć w dalszej części do przetwarzania nowych danych.



Rys. 2.1. Uczenie maszynowe: nowy model programowania

Podsumowując, system uczenia maszynowego jest trenowany, a nie programowany w sposób jawny. Celem programisty jest przedstawienie mu odpowiedniej dużej ilości przykładów wyników, tak by sam system określił ich statystyczną strukturę, co w dalszej części pozwoli na ustalenie reguł umożliwiających automatyzację całego procesu. Ważne, by podkreślić tutaj znaczenie danych wejściowych, które to często określa się terminem *Big Data*[11].

2.1. BIG DATA

Popularyzację tego terminu przypisuję się do wykładu autorstwa Johna Mashey’a[6] jaki wygłosił w 1998 roku. Zauważył on, że wraz ze spadkiem cen nośników do przechowywania i gromadzenia danych, ilość zbieranych przez ludzkość informacji wzrasta z każdym rokiem. Co więcej, ilość tych danych sprawia, że ich analiza przestała być możliwa do realizacji w sposób inny niż automatyczny. Za kryterium, czy dany zbiór informacji można określić jako Big Data, często przywołuje się te podane przez Douglasa Laney’ego[4] i określane mianem 3V, które to rozwija się jako rozmiar(ang. *volume*), różnorodność(ang. *variety*) i prędkość (ang. *velocity*). Oznaczają one kolejno:

- **rozmiar** - dane są zbyt duże by mieściły się na standardowych dyskach twardych,
- **różnorodność** - dane pochodzą z różnych źródeł, są niejednorodne i słabo ustrukturyzowane,
- **prędkość** - tempo napływu nowych danych jest znaczące, co w rezultacie utrudnia ich analizowanie.

Jednym z kluczowych zjawisk przyczyniającym się do procesu nagłego przyrostu ilości i źródeł danych jest Internet przedmiotów (ang. *Internet of Things*[3]). Według tej koncepcji, różnego typu urządzenia osadzone w urządzeniach codziennego użytku(np. odkurzacze, żarówki, instalacje grzewcze), czy też w maszynach przemysłowych, zbierają dane o otoczeniu, czy samym procesie w którym uczestniczą, a ponadto mają możliwość komunikacji pomiędzy sobą, ale również z jednostką centralną jeśli taka występuje. Wprowadza to nowy wymiar w możliwościach automatyzacji procesów i tworzy nową przestrzeń do tworzenia się złożonych, inteligentnych systemów.

2.2. RODZAJE SYSTEMÓW UCZENIA MASZYNOWEGO

Istnieje wiele metod podziału uczenia maszynowego na kategorię. Jedną z najpopularniejszych jest podział ze względu na sposób uczenia się oraz zadanie do wykonania[9]:

- Uczenie nadzorowane:
 - klasyfikacja,
 - regresja.
- Uczenie nienadzorowane:
 - klasteryzacja,
 - redukcja wymiarowości,
 - uczenie przy użyciu reguł asocjacyjnych.
- Uczenie ze wzmocnieniem.

W uczeniu z nadzorem(ang. *supervised learning*), którym zajmę się w poniżej pracy, dane trenujące przekazane algorytmowi zawierają dołączone do nich etykiety, czyli rozwiązania problemu. Celem algorytmu jest stworzenie funkcji(nazywanej też hipotezą[1]), która będzie maksymalizować swoją skuteczność względem zadanych kryteriów.

Na zbiór uczący Z_u składa się zbiór n wektorów, gdzie każdy z nich opisuje pojedynczy obiekt(patrz wzór 2.1):

$$Z_u = \{(x_1, y_1), \dots, (x_n, y_n)\} \quad (2.1)$$

I tak w powyższym równaniu i -ty wektor oznaczony jest jako x_i i odpowiada mu etykieta oznaczona jako y_i . W zależności od typu danych przechowywanych pod etykietą będziemy mieć do czynienia z zadaniem klasyfikacji(etykieta należy do skończonego i przeliczalnego zbioru) lub regresji(wartości przyjmowane przez etykietę należą do przestrzeni ciągłej). Ważne żeby dodać że na wektor x_i może składać się m -liczb, gdzie każdą z tych liczb będziemy nazywać atrybutem lub cechą danego wektora(patrz wzór 2.2):

$$x_i = \{x_{1,m}, \dots, x_{i,m}\} \quad (2.2)$$

Etykietą zaś, w tym rozumowaniu, oznaczamy prawdziwą wartość funkcji, którą to chcemy by nasz algorytm odwzorował. Algorytm ten, nazywamy również modelem i opisujemy go jako następującą funkcję f (patrz wzór 2.3):

$$f(x) : x \in X \mapsto y \in Y \quad (2.3)$$

Jak widać zadaniem powyższej funkcji jest przyporządkowanie wektorom wejściowym etykiet. Jej skuteczność jest mierzona przy użyciu wybranej przez nas metryki na zbiorze testowym. Zbiór testowy musi posiadać tą samą strukturę co zbiór trenujący. Można traktować metrykę M jako funkcję wyższego rzędu, której pierwszym argumentem jest sam model f , a drugim zbiór testowy Z_t . Dziedziną metryki jest zazwyczaj podzbiór liczb rzeczywistych z zakresu od 0 do 1(patrz wzór 2.4)


$$M(f, Z_t) : (f, Z_t) \mapsto m \in [0, 1] \quad (2.4)$$

Przykładem metryk stosowanych w uczeniu maszynowym są między innymi dokładność, czułość, precyzja, a także miara F (ang. *F-score*), które omówione zostały szczegółowo w dalszej części rozdziału.

Wykorzystanie osobnego zbioru do badania jakości modelu w uczeniu nadzorowanym związane jest bezpośrednio z takimi problemami jak nadmierne dopasowanie, przeuczenia(ang. *overfitting*) oraz niedouczenie (ang. *underfitting*)[2]. Zadaniem, które dobrze nadaje się do graficznej ilustracji powyższych problemów jest regresja liniowa. Jak już zostało opisane powyżej w problemie tym, etykiety przykładów są liczbami należącymi do przestrzeni ciągłej, a zadaniem algorytmu jest wyznaczenie funkcji f (patrz wzór 2.5):


$$f(x) : x \mapsto y \in \mathbb{R} \quad (2.5)$$

Dodatkowo dla lepszej interpretacji graficznej każdy wektor w przestrzeni x będzie posiadał tylko jedną cechę. Przykład prawidłowego dopasowania wygląda następująco(patrz rysunek 2.2):




Rys. 2.2. Przykład prawidłowego dopasowania

Problem nadmiernego dopasowania cechuje się tym, że taki model zbyt mocno generuje charakterystykę dla danych trenujących, zawierając w niej również występujące tam szumy(patrz rysunek 2.3):



Rys. 2.3. Przykład nadmiernego dopasowania

Odwrotnym problem jest problem niedouczenia. Występuje on na przykład wtedy, kiedy zastosujemy zbyt prosty model w stosunku do poziomu skomplikowania zbioru danych. Wynik takiej operacji widoczny jest na rysunku 2.4



Rys. 2.4. Przykład niedostatecznego dopasowania

2.2.1. Miary jakości

2.3. ZADANIE KLASYFIKACJI BINARNEJ

2.3.1. Maszyna wektorów nośnych(SVM)

2.4. GŁĘBOKIE SIECI NEURONOWE

2.4.1. VGG

3. ANALIZA ISTNIEJĄCYCH METOD W OBRĘBIE DZIEDZINY

4. ZAŁOŻENIA METODOLOGICZNE

4.1. WYBRANIE ZBIORÓW DANYCH

4.2. OPIS WYKONANYCH EKSPERYMENTÓW

4.3. AUTORSKA METODA WYKORZYSTANIA SIECI KONWOLUCYJNEJ W DETEKCJI FALSYFIKACJI ZDJĘĆ

4.4. INTERPRETACJA UZYSKANYCH WYNIKÓW

5. IMPLEMENTACJA I INTERPRETACJA WYNIKÓW BADAŃ

5.1. IMPLEMENTACJA ŚRODOWISKA RAMOWEGO WYKORZYSTUJĄCEGO ISTNIEJĄCE ARCHITEKTURY SIECI

5.2. IMPLEMENTACJA AUTORSKIEJ METODY WYKORZYSTANIA UCZENIA GŁĘBOKIEGO W ZADANIU KLASYFIKACJI

6. PODSUMOWANIE

BIBLIOGRAFIA

- [1] Cichosz, P., *Systemy uczące się* (Wydawnictwo Naukowo-Techniczne, 2000).
- [2] Géron, A., *Hands-On Machine Learning with Scikit-Learn and TensorFlow* (O'Reilly Media, 2017).
- [3] Holler, J., Tsiatsis, V., Mulligan, C., Avesand, S., Karnouskos, S., Boyle, D., *From machineto-machine to the internet of things: Introduction to a new age of intelligence*, Academic Press. 2014.
- [4] Laney, D., *3d data management: Controlling data volume, velocity, and variety*, tech. rep., META Group. 2001.
- [5] Lovelace, A., Menabrea, L.F., *Sketch of the analytical engine invented by charles babbage... with notes by the translator. translated by ada lovelace*, Scientific Memoirs. 1843.
- [6] Mashey, J.R., *Big data... and the next wave of infrastress*, Slides from invited talk. 1998.
- [7] Menabrea, L.F., *Sketch of the analytical engine invented by charles babbage*, Bibliothèque Universelle de Genève, No. 82. 1842.
- [8] Mitchell, T.M., *Machine Learning* (McGraw-Hill, Inc., 1997).
- [9] Raschka, S., *Python Machine Learning* (Packt Publishing, 2015).
- [10] Samuel, A.L., *Some studies in machine learning using the game of checkers*, IBM Journal of Research and Development(Volume: 3, Issue: 3). 1959.
- [11] Singh, S., Singh, N., *Big data analytics*, Communication, Information Computing Technology (IC-CICT). 2012.
- [12] Turing, A.M., *Computing machinery and intelligence*, Mind(Volume: LIX, Issue: 236). 1950.

SPIS RYSUNKÓW

2.1.	Uczenie maszynowe: nowy model programowania	4
2.2.	Przykład prawidłowego dopasowania	6
2.3.	Przykład nadmiernego dopasowania	6
2.4.	Przykład niedostatecznego dopasowania	7

SPIS TABEL